

Etapas 3

Adecuación y/o validación del Modelo

Integrantes

Carola Vázquez Arjona	A01174562
Paola Michelle Martínez Galeazzi	A00839082
Yamil Elias Del Blanco Chávez	A00838610

Campus Monterrey

Aplicación de métodos multivariados en ciencia de datos

Grupo 101 (Equipo 1)

Profesoras

Blanca Rosa Ruiz Hernández

Adriana Reyna Lara

Fecha de entrega

4 de septiembre, 2025

Objetivo general del proyecto

El objetivo general inicial fue evaluar la efectividad y representatividad del IAS en la Zona Metropolitana de Monterrey dada su topografía y meteorología particulares, y proponer mejoras operativas de comunicación compatibles con la NOM-172. Sin embargo, se tomó la decisión de modificarlo debido a que excede el tiempo disponible y requiere transformaciones e integración de datos más extensos, además de validaciones cruzadas con otras ciudades y periodos.

Por ello, decidimos redefinir nuestro objetivo. El objetivo general ahora es evaluar si la topografía de la Zona Metropolitana de Monterrey (valle vs zonas altas) influye de manera significativa en los niveles de contaminantes atmosféricos, controlando por variables meteorológicas.

Este objetivo entrega una evidencia puntual y reproducible para que, en una fase posterior, pueda ser retomada para la comparación con el IAS.

Análisis de topografía

En esta fase buscamos explorar la estructura espacial y topográfica de las estaciones de monitoreo de la Zona Metropolitana de Monterrey, con el fin de evaluar si la ubicación geográfica y la altitud de cada estación podrían estar asociadas a diferencias en los niveles de contaminantes con el fin de responder a nuestro objetivo específico, antes ya mencionado.

Para la preparación de los datos utilizamos Google Earth Engine y su Modelo Digital de Elevación (DEM) Copernicus GLO-30, que representa la superficie terrestre, incluyendo edificios, infraestructura y vegetación, con resolución de 30 m. Con ello, se calcularon tres capas derivadas del DEM: pendiente, orientación de la pendiente y sombreado.

Se construyó un mapa interactivo centrado en Monterrey, en el que se colocaron marcadores para cada estación de monitoreo. Trazamos círculos de 6 km de radio alrededor de cada estación, con el fin de visualizar la zona de influencia aproximada. Esta representación permitió ubicar las estaciones en relación con la orografía de la ciudad y detectar de manera preliminar cuáles se encuentran en el valle y cuáles en laderas o zonas elevadas.




Figura 1. Localización de las estaciones de monitoreo de la calidad del aire en la zona metropolitana de Monterrey

Cada marcador corresponde a una estación identificada por el nombre. El mapa permite observar la cobertura espacial de la red, evidenciando que la mayoría de las estaciones se concentran en el área central y norte de la zona metropolitana, mientras que hacia la periferia hay menor densidad de puntos.

La superposición de los círculos en el centro indica mayor redundancia y cobertura en zonas urbanas, coherente con la mayor densidad poblacional. Por otro lado, las estaciones de Cadereyta y García destacan como puntos solitarios, ubicados estratégicamente cerca de fuentes industriales.

Cálculo de métricas topográficas alrededor de las estaciones

Para poder caracterizar el contexto físico inmediato de cada estación de monitoreo, se implementó una función de GGE que calcula métricas de relieve dentro de un radio circular alrededor de cada punto de medición. Se evaluaron dos escalas espaciales: 250 metros y 100 metros.

Las métricas extraídas fueron elevación media y desviación estándar (altitud promedio y variabilidad del terreno), pendiente media (inclinación del terreno en el radio) y orientación media (dirección predominante de la pendiente, transformada en sus componentes trigonométricas para facilitar análisis posteriores).

Nuestros resultados preliminares nos permitieron realizar la clasificación entre valle y ladera por estación:

- **Estaciones en valle** (ej. Obispado, Escobedo, ITESM, San Pedro), que se caracterizan por pendientes medias relativamente en algunos casos puntuales pero relieves más contenidos (200 - 800 m) comparados con estaciones en laderas.
- **Estaciones en laderas** (ej. San Bernabé, García, Tec NL) que exhiben pendientes medias elevadas, relieves más marcados y desviaciones estándar de elevación también más altas, lo que indica mayor heterogeneidad topográfica alrededor.

La comparación entre el punto central de la estación y la elevación promedio del borde del radio permite distinguir si las estaciones están en zonas hundidas o en zonas elevadas.


Visualización del relieve

Como complemento del análisis numérico de métricas topográficas, se generaron modelos tridimensionales del terreno en el radio de aproximadamente 6 km alrededor de cada estación de monitoreo.

Las estaciones en laderas y zonas de montaña muestran un relieve muy accidentado, con grandes contrastes verticales. Las estaciones en valles o planicies presentan superficies relativamente homogéneas, con elevaciones que varían menos de 100 m en el entorno. En el centro metropolitano se

observan depresiones rodeadas de bordes elevados, lo que reproduce visualmente el conocido “efecto olla” del área metropolitana: el aire tiende a quedar atrapado por las sierras circundantes.

Estas visualizaciones confirman que la clasificación entre valle y ladera utilizada está respaldada por la morfología real del terreno, con gradientes muy marcados en la topografía entre las diferentes estaciones. Esta heterogeneidad justifica la necesidad de incorporar la variable topográfica como factor explicativo en los modelos estadísticos sobre contaminantes, ya que condiciona la dispersión y acumulación de emisiones.






Figura 2. Modelos tridimensionales del relieve en un radio aproximado de 6 km alrededor de cada estación de monitoreo de la ZMM, obtenidos a partir del DEM Copernicus GLO-30 (30 m de resolución). Las superficies muestran la elevación en metros, donde los tonos azules corresponden a zonas bajas y los tonos marrón-verde a áreas elevadas. Se aprecia la heterogeneidad topográfica entre estaciones: algunas en planicies (Pesquería, Apodaca, Juárez), otras en laderas con gran variabilidad altimétrica (San Bernabé, García, San Pedro, ITESM), y varias en depresiones rodeadas de montañas (Obispado, Escobedo), evidenciando el efecto de “olla” característico de Monterrey.

Técnicas estadísticas utilizadas

El objetivo fue evaluar si la topografía circundante a cada estación agrega señal explicativa sobre los patrones espacio-temporales de contaminación y meteorología. Este análisis se realiza con dos enfoques complementarios:

- Interdependencia a través de un PCA donde se analiza la estructura conjunta de variables.
- Dependencia a través de una regresión donde se analiza la capacidad predictiva por estación.

PCA

Para construir el PCA se trabajó con 15 estaciones meteorológicas, a partir de percentiles P50/P90 de contaminantes y variables meteorológicas (20 métricas: PM₁₀, PM_{2.5}, O₃, NO, NO₂, NO_x, SO₂, CO,

temperatura exterior—TOUT, humedad—RH y radiación—SR). Luego, en un segundo PCA incorporamos ocho métricas topográficas (elevación media y desviación estándar, pendiente media y aspecto). A continuación se analizarán los resultados más relevantes de esta técnica estadística.

PCA sin topografía. Los dos primeros componentes explican 47.6 % de la varianza (PC1=28.8 %, PC2=18.8 %). El PC1 está dominado por la familia de NO_x (NO_x_P90, NO_P90, NO₂_P50/90) y por PM_{2.5} (P50/P90), con aportes de SO₂ y PM₁₀. Este eje resume, de manera coherente, la señal de tráfico/combustión y partículas finas. El PC2 concentra SR_P50, O₃_P90 y RH (P50/P90), junto con NO_P50, por lo tanto, es un eje fotoquímico-meteorológico: radiación y humedad condicionan la formación/destrucción de ozono y la mezcla vertical. En los PC3–PC4 aparecen combinaciones de TOUT (P50/P90), SO₂ y PM₁₀: dinámica térmica y fuentes industriales/resuspensión.

PCA con topografía. Al añadir el bloque topográfico la varianza se redistribuye: PC1=25.7 % y PC2=22.3 % ($\approx$ 48.0 % acumulado en PC1–PC2). El PC1 pasa a estar fuertemente influido por la geometría del terreno, su aspecto, pendiente y elevación media, acompañado por SR_P50 y O₃_P90, por lo tanto, podemos interpretarlo como un eje “orográfico-fotoquímico” que sugiere que la orientación y rugosidad del relieve modulan la disponibilidad de radiación y las condiciones de estancamiento/ventilación. El PC2 reúne de nuevo la familia NO/NO_x y PM_{2.5}, con aportes de la heterogeneidad de elevación, es decir, una mezcla de intensidad de emisión y configuración local del relieve. En PC3–PC4 persisten CO/SO₂/PM₁₀ y TOUT/RH, con presencia secundaria de elevación.

Para no sobrerepresentar las variables topográficas por simple cantidad o escala, también se ejecutó un PCA “block-scaled”, el cual involucró estandarización dentro de bloque y ponderación igual a las variables meteorológicas vs topográficas. En ese escenario el PC1 queda claramente dominado por la geometría del terreno (aspecto y pendientes) y el PC2 por la variabilidad de elevación junto con NO/NO_x y PM_{2.5}. Este resultado refuerza que, cuando el peso de ambos bloques es comparable, la topografía puede organizar los patrones principales.

Estos resultados, a pesar de parecer prometedores, podían ser engañosos. Con la finalidad de distinguir el mero efecto de añadir un bloque nuevo de información, al efecto por la correspondencia estación-topografía se aplicó un control negativo por permutación. Para esto, se barajaron las filas topográficas entre estaciones y se repitió el PCA. La *distancia de Procrustes* entre las proyecciones PC1–PC2 sin y con topografía permutada fue 0.498, mayor que la distancia sin vs con topografía real (0.304), lo que confirma que incorporar el bloque topográfico cambia la geometría del espacio latente. No obstante, la distancia entre la topografía real y la topografía permutada fue 0.141, un coeficiente bastante pequeño, indicando que buena parte del giro en PC1–PC2 proviene del peso del bloque topográfico en sí, y que la asignación específica por estación introduce un ajuste adicional, pero moderado, en los dos primeros ejes. Es justamente aquí, donde intervino un detalle muy importante a considerar en las variables topográficas. Con base en sus características topográficas, se clasificaron las

estaciones en dos clases: Ladera y Valle. Con la clasificación independiente de cada estación se evaluó si los scores PC1–PC2 diferían por grupo. Sin topografía, la diferencia entre medias de PC1 no fue significativa (t de Welch = -0.836 , $p=0.420$) y PC2 mostró una tendencia ($t=-1.910$, $p=0.088$). Con topografía, la separación aumenta: PC1 presenta un valor medio positivo en ladera (0.914) y negativo en valle (-1.371), con un p -valor cercano al umbral ($t=-2.026$, $p=0.074$).

La *PERMANOVA* multivariante ofrece la pieza más sólida para sustentar nuestra hipótesis inicial. El resultado con solo variables meteorológicas y contaminantes, no arrojó separación entre ladera y valle, pero al incluir topografía la separación de centroides es significativa ($F=2.023$, $p=0.0166$). Es decir, el conjunto de variables se organiza espacialmente de manera distinta entre laderas y valles cuando la orografía entra en el análisis.




Figura 3. Modelos de Componentes Principales (PC1 vs PC2) comparando Sin Topografía / Con Topografía. Estaciones en Naranja hacen referencia a Laderas; Azul a Valles. La gráfica ilustra que la topografía introduce un eje de ordenación adicional (PC1) que ayuda a diferenciar laderas y valles, en línea con la *PERMANOVA* que resultó significativa cuando la topografía está presente.

Regresión

En el caso de la regresión, el análisis siguió dos pasos principales. Primero se ajustó un modelo por estación, usando únicamente las observaciones de esa estación, eso permitió ver con detalle cómo responden los contaminantes a la meteorología en un sitio en específico. Segundo, se ajustaron modelos “pooled” (agrupados) con todos los datos de todas las estaciones. En estos modelos se agregaron efectos fijos de estación, mes y hora, lo que significa que el modelo controla automáticamente por diferencias constantes entre estaciones y por variaciones sistemáticas mensuales y horarias. Luego se compararon tres versiones: una sin topografía, otra con la topografía como variable categórica, y una tercera con interacciones entre la topografía y las variables meteorológicas. En todos los modelos se calcularon errores estándar robustos (HAC), que corrigen por heteroscedasticidad y autocorrelación temporal, comunes en datos horarios de calidad del aire.

El pipeline de la regresión se diseñó para capturar de manera sistemática la relación entre meteorología, contaminantes y topografía. Primero se transformaron los datos horarios de todas las estaciones a un formato largo que permitiera incluir la estación como variable explícita. Después se estandarizaron en z-score las variables meteorológicas clave —temperatura, humedad relativa, radiación solar y velocidad del viento— para hacerlas comparables entre sí. Se generaron además transformaciones adicionales, como el cuadrado de la velocidad del viento para representar efectos no lineales, y la interacción entre temperatura y humedad para reflejar condiciones de estabilidad atmosférica. También se incorporó un rezago temporal de los contaminantes para capturar la inercia de las concentraciones. Con estas variables se ajustaron modelos por estación y modelos agrupados que incluyeron efectos fijos de estación, mes y hora, de modo que se controlaran las variaciones sistemáticas espaciales y temporales. Finalmente, se probó el papel de la topografía tanto como variable categórica (valle vs. ladera) como en interacción con las variables meteorológicas, con el fin de identificar si esta modula la sensibilidad de los contaminantes a las condiciones meteorológicas.

Resultados en PM2.5. En la estación Sur, clasificada como valle, el modelo explicó aproximadamente el 60% de la variabilidad de las concentraciones ($R^2 = 0.60$). Allí se observó que la interacción entre temperatura y humedad relativa tuvo un efecto significativo y positivo (0.21, $p = 0.001$), lo que sugiere que en contextos encajonados las condiciones cálidas y secas potencian más la acumulación de partículas que en estaciones de ladera. En los modelos agrupados, el ajuste global fue cercano al 77% ($R^2 \approx 0.77$). La clasificación Valle/Ladera por sí sola no modificó sustancialmente el nivel medio de PM2.5, pero al introducir interacciones sí aparecieron diferencias: en estaciones de valle, la temperatura presentó un efecto adicional de 0.10 ($p = 0.036$) en el aumento de partículas, la eficacia del viento para reducirlas fue menor (interacción positiva de 0.16, $p = 0.01$), y la humedad mostró un comportamiento diferencial respecto a las laderas.




Figura 4. El modelo muestra que la temperatura aumenta el PM2.5 en ambas clases, con mayor efecto en laderas (~0.23) que en valles (~0.18); la humedad solo es significativa en laderas, reduciendo partículas; la radiación no presenta un efecto claro; y el viento disminuye el PM2.5 en ambos casos, aunque es menos eficaz en valles (−0.78 vs. −0.82), reflejando que la topografía encajonada limita la ventilación.

Resultados en O₃. Para el ozono, los modelos alcanzaron ajustes aún mayores. En la estación Sur (valle), se explicó alrededor del 89% de la variación observada ($R^2 = 0.89$), reflejando que la radiación y las condiciones meteorológicas capturan con precisión la dinámica local. A nivel de red, los modelos agrupados mantuvieron un ajuste elevado, cercano al 88% ($R^2 \approx 0.88$). Al incorporar interacciones, se encontró que en estaciones de valle la temperatura tuvo un efecto adicional de 0.26 ($p < 0.001$) en el aumento del ozono, mientras que la humedad relativa actuó con gran fuerza para atenuar su formación (-15.9 , $p < 0.001$). Esto confirma que en ambientes topográficos encajonados la meteorología amplifica los procesos fotoquímicos que controlan el ozono.

Conclusión

En conclusión, el análisis PCA confirma que la topografía no solo reordena la varianza por introducir un bloque nuevo, sino que contribuye a diferenciar los patrones multivariantes entre estaciones ubicadas en laderas frente a valles. Por su parte, la inclusión de la topografía en la regresión permitió detectar que su influencia no es en los niveles medios, sino en la forma en que los contaminantes responden a la meteorología. Con modelos que explican entre el 60% y casi el 90% de la variación, se comprobó que en estaciones de valle la temperatura y la humedad relativa ejercen un papel más marcado sobre las concentraciones de PM_{2.5} y O₃, y que el viento es menos eficaz como mecanismo de dispersión. Estos resultados confirman la relevancia de incorporar explícitamente la clasificación topográfica en los modelos de calidad del aire para Monterrey.

Dado el tamaño muestral (15 estaciones), una siguiente etapa razonable es un PCA/Análisis factorial restringido por clase o una RDA (redundancy analysis) que controle explícitamente por topografía para medir cuánta varianza de las variables meteorológicas/contaminantes es explicada por el relieve. Complementariamente, replicar el análisis por temporada y por régimen de viento permitiría capturar efectos de canalización y estancamiento que el PCA anual puede diluir.

GitHub:

<https://github.com/carolavazquez/RETO-MA2003B>