

Etapas 2

Conociendo los datos

Integrantes

Carola Vázquez Arjona	A01174562
Paola Michelle Martínez Galeazzi	A00839082
Yamil Elias Del Blanco Chávez	A00838610

Campus Monterrey

Aplicación de métodos multivariados en ciencia de datos

Grupo 101 (Equipo 1)

Profesoras

Blanca Rosa Ruiz Hernández

Adriana Reyna Lara

Fecha de entrega

28 de agosto, 2025

Objetivo general del proyecto

Evaluar la efectividad y representatividad del IAS en la Zona Metropolitana de Monterrey dada su topografía y meteorología particulares, y proponer mejoras operativas de comunicación compatibles con la NOM-172.

Objetivo del Análisis Descriptivo

Las actividades realizadas en el análisis descriptivo fue caracterizar, depurar y documentar el comportamiento de los contaminantes criterio ($PM_{2.5}$, PM_{10} , O_3 , NO_2/NO_x , SO_2 , CO) y de las variables meteorológicas (viento, temperatura, humedad, presión, radiación, precipitación) en la Zona Metropolitana de Monterrey durante el periodo 2023–2024. El objetivo general fue entender sus distribuciones, estacionalidad y variación por estación, verificar y mejorar la calidad del dato (nulos, outliers, duplicados, unidades), y generar un dataset listo para análisis que soporte, en etapas siguientes, la reconstrucción normativa del IAS y la evaluación de su representatividad bajo la topografía específica de Monterrey. Los objetivos específicos serán presentados a continuación:

- Describir la distribución y forma de cada variable por estación e identificar patrones.
- Cuantificar la variabilidad con medidas robustas y detectar valores atípicos.
- Explorar relaciones entre contaminantes y meteorología.
- Auditar la calidad (nulos, duplicados) y documentar las correcciones aplicadas.

Técnicas estadísticas utilizadas

La primera técnica estadística utilizada fue la descripción univariada por estación y variable. Para poder lograr esta descripción se explicó la tendencia central (media, mediana, moda), la dispersión y forma (mínimo, máximo, rango, desviación estándar, varianza, IQR asimetría y curtosis), se utilizaron visuales (Histogramas/KDE, Boxplots por estación, y Climatologías diarias y semanales), y se analizó la robustez (cuando haya colas pesadas).





La segunda técnica utilizada fue la detección y manejo de outliers, basándonos en reglas físico-plausibles para la eliminación/conservación de valores, por ejemplo, PM no negativa; $PM_{10} > 1000 \mu g/m^3$ y $O_3 > 400$ ppb marcados como sospechosos; $WSR \geq 0$; WDR en $[0, 360]$; además, se detectaron valores imposibles de humedad relativa (RH) y radiación solar (SR) — algunos registros aparecían con magnitudes como -10,000, lo cual carece de sentido físico y sabemos que deriva de algún fallo en la medición —. Para garantizar consistencia, se aplicó una segunda limpieza específica: se establecieron rangos válidos de 0 a 100% para la humedad relativa, y de 0 a 1 para la radiación solar relativa. Así, evitamos que los valores atípicos distorsionen las distribuciones y análisis posteriores.





La tercera técnica utilizada fue la verificación de la calidad del dato a través del conteo de nulos (conteos y % por columna), la eliminación de duplicados (por clave), la verificación de unidades y formatos (confirmación de $ppb/ppm/\mu g \cdot m^{-3}$), la aplicación de imputación escalonada

definida por Interpolación lineal para huecos ≤ 6 h, Filtro de Kalman / StructTS para huecos > 6 h y ≤ 24 h, > 24 h: sin imputar (se conserva NA). La cuarta técnica utilizada fue la estadística para relaciones y dependencias, como las correlaciones entre variables cuantitativas (contaminantes + variables meteorológicas), y la relación de los sectores con las estaciones (variables cualitativas). Para facilitar el análisis de la relación entre las variables cualitativas se utilizaron gráficos de Rosas de viento por estación.


Variables necesarias y sus principales características estadísticas

Las principales variables necesarias son el Núcleo IAS, las contaminantes criterio (series horarias por estación). Estas variables son las que permiten reconstruir los subíndices IAS y evaluar su representatividad espacial/temporal en la Zona metropolitana de Monterrey.


Variable	Rol	Estadística y forma	Gráficos
PM ₁₀ ($\mu\text{g}/\text{m}^3$)	Subíndice IAS de PM ₁₀ , es el diagnóstico de resuspensión/episodios.	Su distribución es muy asimétrica a la derecha con cola larga, medianas en decenas de $\mu\text{g}/\text{m}^3$; IQR amplio, muchos outliers altos entre estaciones. Los picos >1000 $\mu\text{g}/\text{m}^3$ recodificados a NA.	
PM _{2.5} ($\mu\text{g}/\text{m}^3$)	Contaminante más crítico para salud, funciona como comparación OMS/EPA.	Asimetría positiva y colas pesadas, medianas en decenas, gran dispersión y variación espacial. Los valores atípicos extremos se recodificaron a NA.	
O ₃ (ppb)	Oxidante vespertino, clave en temporada cálida.	Unimodal con asimetría, medianas en decenas de ppb, IQR intermedio, picos en tardes soleadas.	
NO ₂ (ppb)	Marcador de tráfico, precursor de O ₃ /partículas.	Distribución asimétrica, medianas en decenas, IQR visible, outliers en horas pico.	

NO (ppb)	Emisión fresca de combustión, titula O ₃ .	Muy asimétrica, medianas bajas y picos muy altos (colas largas).	
NOx (ppb)	Suma de NO+NO ₂ .	Patrón entre NO y NO ₂ : correlaciones positivas y colas.	
SO ₂ (ppb)	Señal de fuentes industriales.	Cercano a cero la mayor parte del tiempo con picos esporádicos (decenas o más).	
CO (ppm)	Combustión incompleta, exposición urbana.	Medianas bajas (≈1–3 ppm), asimetría positiva, episodios discretos.	

El segundo conjunto de variables necesarias son las variables de Meteorología. Estas variables explican por qué cambia el contaminante dominante y sustentan la hipótesis topográfica/meteorológica que queremos confrontar con el IAS.

Variable	Rol	Estadística y forma	Gráficos
WSR (m/s)	Ventilación vs. estancamiento; clave para PM y dilución de NOx/CO.	Distribución con pico en vientos débiles y cola hacia valores altos, diferencias por estación, outliers puntuales en una estación. (Véase anexo 1)	Distribución de WSR por estación 


WDV (°)	Es la base para las rosas de viento.	Rosas muestran predominio de E-SE/NE con variación local Coherente con recirculaciones de valle como en Monterrey.	
TOUT (°C)	Favorece fotoquímica (O ₃) y evolución diurna de estabilidad.	Violin plots con gradiente diurno/estacional, outliers aislados. (Véase anexo 2)	
SR (sensor)	Motor de formación de O ₃ , cero nocturno.	Distribución cero-inflada nocturna y picos diurnos, diferencias espaciales. (Véase anexo 3)	
RH (%)	Modula higroscopicidad y deposición de PM.	Amplio rango (cajas altas), medianas ~40-70% según estación. (Véase anexo 4)	
PRS (sensor)	Indicador de masa de aire/estabilidad.	Unimodal cercana a normal, mediana ~710 y DE moderada, variación entre estaciones. (Véase anexo 5)	



El último conjunto de variables necesarias son las variables descriptivas como hora local, día de semana, mes/temporada , sectores de viento y velocidad.

Relaciones entre variables

Se analizó la correlación entre cada contaminante y variable meteorológica, lo cual puede ser observado en el gráfico presentado a continuación.



La mayoría de las correlaciones son menores a 0.20. Las únicas correlaciones claramente fuertes son entre especies de nitrógeno ($\text{NO}_2\text{--NO}_x \sim 0.58$; $\text{NO--NO}_x \sim 0.33$), lo cual se debe a que explican información redundante al NO_x ser la suma de $\text{NO}+\text{NO}_2$. Por su parte, O_3 muestra lo esperable, una mayor correlación con T, y menor con RH/WSR/PRS. PM tiene correlaciones lineales globales muy bajas con las variables meteorológicas a escala horaria, por lo tanto, su análisis debe ser condicional (viento débil, lluvia, sectores de viento).

Conclusión

Con la resolución de esta etapa lo logrado fue la documentación de un marco analítico alineado al IAS y a la hipótesis topográfica. También se realizó la exploración descriptiva completa por contaminante y estación. La construcción de rosas de viento por estación y correlaciones entre contaminantes–meteorológicas que explican relevos intradiarios. Control de la calidad de los datos inicial con reglas físico-plausibles e imputación escalonada (≤ 6 h lineal; 6–24 h Kalman; >24 h sin imputar).

Lo que falta por hacer es consolidar las climatologías por hora/temporada y bi variado concentración~(WDV, WSR) para $PM_{2.5}/PM_{10}/O_3$. Reconstruir subíndices IAS (ventanas normadas) y calcular el “peor subíndice” por estación/hora. Contrastar representatividad espacial del IAS, tomando información topográfica de la Zona Metropolitana de Monterrey. Con toda la información recabada y después de hacer un análisis exhaustivo de la topografía se espera hacer una síntesis ejecutiva para la toma de decisiones y un posible replanteamiento del IAS en Nuevo León.

Para concluir nos parece relevante plantear las preguntas que guiarán la siguiente etapa:


- ¿El “peor subíndice” por estación representa bien la exposición local en un valle con microambientes?
- ¿En qué sectores de viento aparecen los picos de $PM_{2.5}/PM_{10}$ y de O_3 ?
- ¿Qué diferencias de categoría IAS se observan entre estaciones cercanas durante el mismo episodio?

GitHub:


<https://github.com/carolavazquez/RETO-MA2003B>

Anexos


Anexo 1. Distribución global de WSR (todas las estaciones)




Anexo 2. Distribución global de TOUT (todas las estaciones)




Anexo 3. Distribución global de SR (todas las estaciones)



Anexo 4. Distribución global de RH (todas las estaciones)



Anexo 5. Distribución global de PRS (todas las estaciones)



Anexo 6. Distribución global de RAINF (todas las estaciones)

En el histograma, vemos una gran barra en 0, confirmando que la mayoría de las mediciones reportan nada de lluvia, dejando casi invisibles a los otros días con valores positivos en esa escala.

